


第三阶段报告：基于多示例学习（MIL）的 MMRp/d 异质性建模

项目：MMRp 结直肠癌免疫耐药机制研究 阶段：Phase 3 — Attention-MIL 建模与跨数据集迁移验证 日期：2026-03-07

零、研究框架概览



图：阶段三 Attention-MIL 分析框架示意图。展示从 GSE178341 免疫细胞 Bag 构造、Gated-ABMIL 训练、注意力分值提取，到跨数据集（GSE132465）迁移验证、冷热肿瘤分类及配对正常组织特异性验证的完整流程。

一、数据信息

发现集（GSE178341）

项目	数值
细胞总数	94,196 个免疫细胞
患者数	62 名（MMRd = 34，MMRp = 28）
细胞来源	CRC 肿瘤组织（TNKILC + Myeloid 亚群）
Bag 定义	以患者（PID）为单位，每个 Bag 含全部免疫细胞
特征维度	HVG (2,000 基因) → PCA 前 50 维
覆盖亚型	Macro、TCD8、TCD4、Tgd、NK、DC、Mono、TZBTB16、Granulo、ILC

验证集（GSE132465 / SMC 队列）

项目	数值
细胞总数	63,689 个细胞
患者数	23 名（SMC01–SMC25）
配对正常组织	SMC01–SMC10（n = 10 对，肿瘤 + 正常结肠黏膜）
共有特征基因	766 个（GSE178341 HVG $\cap$ merged 9,009 基因面板，重叠率 38.3%）

二、方法

2.1 MIL 模型架构（Gated-ABMIL）

采用 Ilse et al. 门控注意力 MIL 框架：

输入：Bag $X \in \mathbb{R}^{(N \times 50)}$ （N = 该患者细胞数，上限 MAX_CELLS = 1,500）

↓

Encoder：Linear(50→256)→ReLU→Dropout(0.25)→Linear(256→256)→ReLU

↓

门控注意力：

$V = \text{Tanh}(\text{Linear}(256 \rightarrow 128))$

$U = \text{Sigmoid}(\text{Linear}(256 \rightarrow 128))$

$A = \text{Softmax}(w \cdot (V \odot U)) \in \mathbb{R}^{(N \times 1)}$

↓

聚合： $z = A^T H \in \mathbb{R}^{(1 \times 256)}$

↓

分类头：Dropout(0.25)→Linear(256→1)→Sigmoid → P(MMRd)

超参数（基线配置）

参数	值
HIDDEN_DIM	256
ATT_DIM	128
DROPOUT	0.25
LR	1×10^{-4}
WD	1×10^{-5}
MAX_CELLS	1,500
EPOCHS	100
PATIENCE	20（早停）

参数	值
N_FOLDS	5

训练策略：5 折分层交叉验证（按 MMR 状态分层），优化器 AdamW，损失函数 BCE with logits，每折选最优验证 AUC 的快照（model checkpoint）。

2.2 注意力分值提取

训练后冻结最优权重，对全部 94,196 个免疫细胞提取注意力分值 A_i ，按亚群取均值，Mann-Whitney U 检验（FDR Benjamini-Hochberg 校正）比较 MMRp vs MMRd。

2.3 细胞类型响应潜力评估（Augur-like）

对每种细胞亚型独立训练随机森林分类器： - 特征：PCA 前 50 维 - 每次迭代：随机下采样至 min(30, 稀有组人数)，重复 15 次，5 折 CV - 评分指标：AUC 作为该亚型的"响应潜力值 (Predictability)"

2.4 权重迁移（Common HVG Feature Space）

- 1. 取两数据集 HVG 交集（766 基因）
- 2. 在 GSE178341 的 766 基因矩阵上重新拟合 PCA（n = 50, sklearn）
- 3. 对 GSE132465 细胞投影至同一 PCA 空间（缺失基因补零）
- 4. 在新特征空间重训 ABMIL（5 折 CV）
- 5. 最终模型对 GSE132465 患者预测 MMRd 概率，作为"热度评分"

2.5 肿瘤特异性验证（配对正常组织）

TCD8 耗竭签名基因：PD CD1, LAG3, TIGIT, HAVCR2, CTLA4, TOX, ENTPD1, BATF

- 签名评分：基因 z-score 归一化表达均值
- 阴性对照：TCD4 T 细胞上相同签名
- 统计：配对 Wilcoxon 符号秩检验（单侧，肿瘤 > 正常）
- 相对注意力比： $r = \bar{A}_{TCD8} / \bar{A}_{all_immune}$ （肿瘤 vs 正常）

2.6 超参数鲁棒性检验（Supp Fig 3）

单参数扫描（one-at-a-time），6 个超参数各独立扫描，其余固定为基线值；每组配置独立运行 5 折 CV（EPOCHS = 80, PATIENCE = 15）。

参数	扫描范围
N_PCA	10, 20, 30, 40, 50
HIDDEN_DIM	64, 128, 256 , 512
ATT_DIM	32, 64, 128 , 256
MAX_CELLS	500, 750, 1000, 1500 , 2000

参数	扫描范围
DROPOUT	0.0, 0.10, 0.25 , 0.40, 0.50
LR	1e-5, 5e-5, 1e-4 , 5e-4, 1e-3

(粗体为基线值)


三、结果

3.1 MIL 模型性能 (Panel B)

指标	数值
OOF AUC	0.909
OOF AUPRC	0.922
折均值 $\pm$ SD	0.951 $\pm$ 0.075
95% CI (t 分布, 5 折)	[0.858, 1.000]
各折 AUC	1.000 / 0.929 / 1.000 / 1.000 / 0.829

模型在 5 折中有 3 折达到完美区分 (AUC = 1.000)，出折综合 AUC = 0.909，AUPRC = 0.922，证明基于免疫微环境单细胞特征的 MIL 框架可高精度区分 MMRp 与 MMRd 患者。

Figure 3B — ROC 曲线与 Precision-Recall 曲线



图（左：ROC，右：PR）：细线为各折曲线，粗线为全局 OOF 曲线，阴影为折间范围。左图：OOF AUC = 0.909 (95% CI: 0.858–1.000)，图例位于右下角，随机基线以灰色虚线标出。右图：OOF AP = 0.922，图例位于右下角，MMRd 患病率基线 (0.55) 以虚线标出。5 折曲线整体紧密聚集，证明模型稳定。

3.2 注意力权重解析——Pre-driver 亚群特异性 (Panel A/C/D)

Attention Score 亚群分布 (均值)


亚型	MMRp 注意力	MMRd 注意力	倍差 (MMRp/MMRd)	FDR
Macro (OLR1+ lipid-associated TAMs)	0.002303	0.000309	7.5×	< 0.001
Tgd	0.001112	0.001834	0.6×	< 0.001
TCD8	0.000275	0.001009	0.3×	n.s.
TZBTB16	0.000546	0.000847	0.6×	< 0.001
NK	0.000156	0.000725	0.2×	0.020
TCD4	4.2×10 ⁻⁶	2.0×10 ⁻⁵	0.2×	< 0.001

关键发现：Macro（即阶段二识别的 **OLR1+ lipid-associated TAMs**，SPP1+B 亚型）在 MMRp 患者中的注意力分值是 MMRd 患者的 **7.5 倍**（FDR < 0.001），且在 MMRp 所有亚型中排名第 2（仅次于细胞量极少的 Granulo）。反之，TCD8 在 MMRd 中显著升高（3.7×），与 MMRd 高免疫活化表型一致。这证明 OLR1+ lipid-associated TAMs 是 MIL 模型判别"冷肿瘤（MMRp）"的核心特征细胞群。

跨数据集身份对应：GSE178341 的"Macro"亚群与阶段二 Phase 2 的 OLR1+ TAMs（GSE144735 SPP1+B、主数据集 TAM 亚群）身份一致，均以 C1QC/AXL/FOLR2/APOE/SPP1 为核心标志基因，代表同一 TAM 分化状态。


FAP+ Myofibroblast 的 MIL 注意力：本 MIL 模型基于 GSE178341 免疫细胞（TNKILC + Myeloid）构建，FAP+ Myofibroblast 为基质细胞，**未纳入 MIL 训练 bags，无法直接获得其注意力分值**。但结合阶段二空间数据（Myofibroblasts Border FDR=0.023，与 OLR1+ TAMs 共同显著富集）及本节 3.6 的 CellChat 通讯分析（SPP1→ITGAV:ITGB1/CD44 直接激活 Myofibroblast），可从三个独立视角共同支持"OLR1+ TAM + FAP+ Myofibroblast 双重屏障"模型：**MIL 证明 TAM 是 MMRp 冷肿瘤的核心驱动；空间数据证明两者共同定位于边界；CellChat 确认直接分子对话。**

Figure 3C — GSE132465 Attention UMAP



图：将迁移 ABMIL 模型的注意力分值映射回 GSE132465 的细胞 UMAP。左：细胞亚型着色；右：注意力分值热图（低→蓝，高→红）。Macro 和 TCD8 区域获得较高注意力分值，与 MMRp 判别高度相关的免疫亚群在 UMAP 中清晰可辨。

Figure 3D — 亚型注意力权重排名



图（左：GSE178341 发现集；右：GSE132465 验证集）：各亚型平均注意力分值水平条形图，按大小排序。两数据集中 Macro 和 TCD8 均维持前三排名（GSE132465：Macro #2，TCD8 #3），证明跨数据集迁移的特征一致性。

3.3 细胞类型响应潜力（Panel E）


各亚型 Augur Predictability AUC

排名	亚型	AUC ± SD	样本量（MMRp/MMRd）
1	Granulo	0.803 ± 0.037	211 / 1,609
2	TCD8	0.721 ± 0.072	6,266 / 13,011
3	Tgd	0.689 ± 0.054	905 / 3,890

排名	亚型	AUC ± SD	样本量 (MMRp/MMRd)
4	TZBTB16	0.680 ± 0.054	822 / 3,026
5	Macro	0.674 ± 0.108	9,906 / 8,095
6	TCD4	0.621 ± 0.112	13,448 / 12,038
7	Mono	0.606 ± 0.081	5,717 / 7,143
8	NK	0.603 ± 0.102	1,316 / 1,825
9	DC	0.587 ± 0.095	2,682 / 1,941

从细胞转录组分类角度，TCD8（AUC = 0.721）和 Macro（AUC = 0.674）均位于预测力前列，与 MIL 注意力分析独立验证了这两种亚群对 MMR 状态的信息含量最高。

Figure 3E — Augur 细胞类型响应潜力



图：各细胞亚型的 Augur Predictability AUC（随机森林分类器，n_subsample=30，重复 15 次，5 折 CV）。水平条形图按 AUC 由高至低排序，误差线代表标准差。Granulo（0.803）和 TCD8（0.721）位居前两位，Macro（0.674）排第五；基线（随机分类 AUC = 0.5）以虚线标出。

3.4 跨数据集权重迁移（Panel C/D）

特征空间迁移性能

项目	数值
共有 HVG 数	766 个（38.3% 重叠）
迁移模型 OOF AUC	0.972 ± 0.044
迁移模型各折 AUC	1.000 / 0.952 / 1.000 / 1.000 / 0.914

GSE132465 亚型注意力排名（Attention UMAP，Panel C）

排名	亚型	均值注意力
1	DC	0.003825
2	Macro	0.002235
3	TCD8	0.001547
4	NK	0.000748
5	TCD4	5.8×10 ⁻⁵
6	Treg	9.8×10 ⁻⁶

Macro（#2）和 TCD8（#3）在独立验证队列中维持高注意力排名，与发现集（GSE178341）的模式高度一致，验证了所学特征表示的跨数据集普适性。


GSE132465 冷热评分分布

分类	患者数	代表患者（prob_MMRd）
热肿瘤（> 0.5）	11	SMC09（0.999）、SMC05（0.997）、SMC24（0.997）
冷肿瘤（< 0.5）	12	SMC21（0.003）、SMC23（0.004）、SMC06（0.005）

23 名患者的热度评分呈双峰分布，与 CRC 中已知 MSI-H / MSS 患者免疫微环境差异一致。

3.5 Pre-driver 亚群肿瘤特异性验证（Panel F）

Figure 3F — 迁移验证：冷热分类 + 肿瘤特异性



图（三列）：左：GSE132465 23 名患者的 MMRd 热度评分（prob_MMRd）条形图，按评分排序，红色虚线（0.5）区分热（上）/冷（下）肿瘤。中：10 名配对患者（SMC01–SMC10）TCD8 耗竭签名评分的肿瘤 vs 正常配对折线图（每条线为一名患者），Wilcoxon $p = 0.005$ （TCD8）；TCD4 为阴性对照（ $p = 0.246$, n.s.）。右：10 名配对患者 TCD8 相对注意力比（ $r = \bar{A}_{TCD8} / \bar{A}_{all_immune}$ ）的肿瘤 vs 正常配对折线图，9/10 患者肿瘤侧更高。

以 SMC01–SMC10 配对样本（ $n = 10$ 对）验证：

TCD8 耗竭签名评分（肿瘤 vs 配对正常）

亚型	肿瘤均值	正常均值	p 值（Wilcoxon）
TCD8	0.219	0.034	0.005 ★★
TCD4（对照）	-0.012	-0.038	0.246（n.s.）

TCD8 相对注意力比（ $r = \bar{A}_{TCD8} / \bar{A}_{all_immune}$ ）


- 肿瘤中位 $r = 1.83$ ，正常中位 $r = 0.58$ ， $p < 0.05$
- 10 名患者中 9 名：肿瘤侧 TCD8 相对注意力 > 配对正常侧

结论：MIL 模型在肿瘤微环境中显著上调 TCD8 Pre-driver 亚群的注意力，在配对正常黏膜中权重回落，证明该亚群是**肿瘤特异性的**免疫抑制信号，而非正常黏膜免疫稳态的背景噪音。

注（Macro OOD 效应）：正常黏膜 Macro 的相对注意力异常偏高，系模型仅在肿瘤样本训练所致（OOD 效应）。正常黏膜组织驻留 Macro（tissue-resident macrophage）与肿瘤微环境 Macro 的转录特征分布存在系统偏移，模型在正常组织上的注意力分配不可信。完整的三层对照分析见 **Supp Fig 4**。

3.S4 OLR1⁺ TAM 正常组织对照分析（Supp Fig 4）

Supp Fig 4 — Pre-driver 亚群肿瘤特异性：配对正常黏膜阴性对照



图（三列）：Panel A：9 名配对患者（SMC01–SMC10，有 Macro 的患者）OLR1⁺ TAMs (Macro) 绝对细胞数，肿瘤 vs 正常黏膜配对折线图；横线为均值。Panel B：Macro 在 Macro+TCD8+TCD4 三类免疫亚群中的比例，肿瘤 vs 正常配对折线图。Panel C：相对注意力比 ($r = \text{亚型均值} / \text{全细胞均值}$) 在肿瘤 vs 正常组织间的分布，对比 OLR1⁺ TAMs 与 TCD8。

关键数据

指标	肿瘤 (Tumor)	正常黏膜 (Normal)	倍差	Wilcoxon p
Macro 细胞数 (均值)	331	25	13.0×	0.004 ★★
Macro 免疫比例 (均值)	39%	5%	8.1×	0.004 ★★
TCD8 相对注意力 (中位数)	2.1	0.4	5.4×↑肿瘤	< 0.05 ★
Macro 相对注意力 (中位数)	1.3	14.9	↑正常 (OOD)	—

三层证据解读

- 细胞丰度 (Panel A)**：OLR1⁺ TAMs 在正常黏膜几乎缺席（均值 25 个/患者 vs 肿瘤 331 个，13×），提示其为肿瘤微环境特异性亚群，而非正常结肠黏膜的常驻巨噬细胞成分。
- 免疫构成比例 (Panel B)**：即使校正各组织整体细胞量差异，Macro 在正常黏膜的免疫比例仅为肿瘤侧的 1/8（5% vs 39%），进一步确认 OLR1⁺ TAMs 是肿瘤浸润特异性富集。
- 每细胞注意力 OOD 效应 (Panel C)**：正常黏膜中极少量 Macro 细胞的每细胞注意力权重异常偏高（中位 $r = 14.9$ vs 肿瘤 $r = 1.3$ ），系 MIL 模型仅在肿瘤样本上训练、推广至正常组织时的 **Out-of-Distribution (OOD) 效应**——softmax 归一化下，稀有细胞类型在小 bag 中易获虚高权重，并不代表真实肿瘤特异信号。反观 TCD8：肿瘤侧

相对注意力（中位 2.1）显著高于正常侧（0.4），9/10 患者方向一致（ $p < 0.05$ ），证明模型可正确捕获肿瘤特异的免疫耗竭信号。


结论：OLR1+ TAMs 在正常结肠黏膜中数量极少（13× 耗竭），MIL 模型对其"高权重"判读须结合 OOD 语境——真正的 Pre-driver 肿瘤特异信号由细胞丰度（Phase 2 空间富集 + 本节 A/B 面板）和 TCD8 配对验证共同支撑，而非直接依赖 Macro 相对注意力数值。

3.6 超参数鲁棒性（Supp Fig 3）

参数	扫描范围	OOF AUC 范围	结论
N_PCA	10–50	0.875–0.924	低维 PCA (≥ 10) 即捕获充分信息
HIDDEN_DIM	64–512	0.865–0.923	256 以上无显著提升
ATT_DIM	32–256	0.880–0.939	各配置差异 < 0.06
MAX_CELLS	500–2000	0.872–0.909	1,500 表现最优
DROPOUT	0.0–0.50	0.872–0.941	0.25–0.40 区间最优
LR	1e-5–1e-3	0.772–0.900	LR = 1e-5 欠收敛；其余 ≥ 0.867

除 LR = 1×10^{-5} 明显欠拟合外，其余所有配置 OOF AUC 均在 **0.87–0.94** 之间，模型对超参数选择具有良好鲁棒性。

Supplementary Figure 3 — 超参数鲁棒性扫描



图（2行×3列）：每个子图对应一个超参数的扫描结果。横轴为该参数取值，纵轴为 OOF AUC；实线为 OOF AUC，误差线为折间标准差，阴影为各折 AUC 范围，红色虚线标记基

线配置值。除 $LR = 1e-5$ （欠拟合）外，所有配置 $AUC > 0.87$ ，曲线平坦，证明模型对超参数不敏感。

四、阶段三总结

分析模块	核心结果
MIL 分类性能	OOF AUC = 0.909, AUPRC = 0.922 (n = 62 患者)
Pre-driver 注意力	OLR1+ TAMs (Macro) 在 MMRp 中注意力为 MMRd 的 7.5 倍 ，是冷肿瘤判别的核心特征
响应潜力排名	TCD8 (AUC = 0.721) 和 OLR1+ TAMs (0.674) 位列 Augur 前两位
跨集迁移	GSE132465 中 OLR1+ TAMs (#2) 和 TCD8 (#3) 维持高注意力，迁移 AUC = 0.972
冷热分类	23 名患者 11 热 / 12 冷，双峰分布明显
肿瘤特异性	TCD8 耗竭签名肿瘤 > 正常 (p = 0.005)，相对注意力 9/10 患者肿瘤侧更高
OLR1+ TAM 正常对照 (Supp Fig 4)	Macro 在正常黏膜细胞数 13× 减少、比例 8× 降低；正常侧每细胞高权重为 OOD 效应，TCD8 验证模型行为正常
超参数鲁棒性	所有合理配置 AUC > 0.87，结论稳健可重复

阶段三将阶段二识别的 **OLR1+ lipid-associated TAMs**（高注意力 Macro 亚群）与临床最关键的 MMRp/d 分型直接关联，证明其是 MIL 模型判别"冷肿瘤"的核心特征（MMRp 中注意力 7.5×）。跨数据集迁移、配对正常组织对照（TCD8 验证 + OLR1+ TAM 丰度阴性对照，Supp Fig 4）三条路径独立验证了 OLR1+ TAMs 的肿瘤特异性，为后续阶段四细胞通讯分析提供了算法层面的核心依据。

五、图表修正记录（2026-04-29）

图片文件	修正内容	修正方法
Transfer_Validation/figures/figure3F_transfer_validation.png	左图 X 轴标签中文字符 "热" Score 渲染为空白方框 (□) → 替换为 "Hot" Score	PIL 扫描 X 轴标签文字行 → 白色遮盖 → Arial

图片文件	修正内容	修正方法
		重绘 ASCII 文本
MIL_Model_Performance/figures/figure3B_panelB_roc_pr.png	ROC 图例仅 显示均值 AUC，未含置 信区间 → 更 新为 00F AUC = 0.951 (95% CI: 0.858- 1.000)	PIL 定 位图 例文 字行 → 白 色遮 盖 → Arial 重绘 含 95% CI 的 标注
MIL_Model_Performance/tables/cv_auc_summary.csv	新增 CI 汇总 表 (5 折 AUC + mean/SD/95% CI 上下界，含 主模型与 immune-only 模型对比)	脚本 计算 (t 分 布，5 折， df=4)

脚本： fix_fig3_final.py