

张明鸣-整合单细胞图谱与多示例学习识别结直肠癌中驱动MMRp 免疫耐药的“前驱动”抑制性亚群及其演化机制

研究空白

尽管单细胞转录组学（scRNA-seq）在解析结直肠癌（CRC）肿瘤微环境（TME）异质性方面已取得了长足进步，但目前的研究仍存在几个关键的知识鸿沟。首先，现有研究大多聚焦于晚期恶性肿瘤的截面分析，缺乏从肠道慢性炎症（如溃疡性结肠炎）到原发性癌变时空演进过程中，免疫逃逸屏障起源的连续动态视角。这种时间维度的缺失，导致我们难以识别在肿瘤发生“极早期”便已极化并决定后续耐药表型的“前驱动（Pre-driver）”抑制性细胞亚群。

其次，错配修复完整（MMRp）型 CRC 作为临床免疫治疗的“冷肿瘤”难点，其形成的底层动力学机制尚不明确。现有的研究虽观察到 MMRp 肿瘤内 T 细胞浸润不足，但未能阐明是否存在特定的抑制性亚群在空间上构建了物理屏障，或在代谢上形成了竞争优势，从而系统性地诱导了免疫排斥环境。

此外，由于跨中心、跨测序平台（如 10x 与 SMART-seq2）的数据存在显著的批次效应，传统的线性整合方法往往会掩盖低丰度但具有关键驱动作用的罕见细胞状态，限制了对全球多中心大数据集的深度挖掘。更为重要的是，目前仍缺乏一种稳健的计算框架，能够将海量单细胞转录组特征与临床最核心的 MMR 分型及左右侧解剖部位差异直接联系起来。由于缺乏具备临床可解释性的深度学习预测模型（如多示例学习，MIL），我们难以在单细胞水平上精准锁定那些真正决定患者预后及免疫响应异质性的“关键实例”细胞。

因此，亟需通过集成生成式深度学习算法与时空多组学图谱，系统性地揭示 Pre-driver 亚群在 CRC 免疫进化中的地位，从而为打破 MMRp 耐药屏障提供全新的细胞靶点。

数据集详情

Dataset Accession	Disease	Sample Type / Tissue	Data type	platform	Country	samples (N)	Disease (N)	Normal (N)
GSE146771	colon cancer	tissues	scRNA-seq	SMART-seq2 10x	China	20	20	0
GSE188711	colorectal cancer	tissues	scRNA-seq	10x	China	6	6	0
GSE132465	colorectal cancer	tissues	scRNA-seq	10x	South Korea	33	23	10
GSE144735	colorectal cancer	tissues	scRNA-seq	10x	South Korea	18	12	6

GSE132257	colorectal cancer	tissues	scRNA-seq	10x	South Korea	10	5	5
GSE125527	溃疡性结肠炎	rectum"（直肠）、"PBMC"（外周血单核细胞）和"ileum"（回肠）	scRNA-seq	10x		54	30	24
GSE150115	Ulcerative Colitis	blood and intestinal tissue	scRNA-seq	10x	USA	5	5	0
GSE178341	colorectal cancer	tissues	scRNA-seq	10x	Israel	181	129	52
ollections/1cbfb478-2c7f-4d15-b522-9f74e9fe52a8	ite-stable colore tumor samples		scRNA-seq	10x		83	28990 cells	18117 cells
TCGA-COAD	0Cancer%20(COAD)&removeHu		RNA-seq					

研究方案

数据集使用建议

研究阶段	核心数据集	样本关键特征	融入后的科研价值
阶段一：全景 Atlas 构建	GSE150115 (UC), GSE125527 (UC) , GSE146771, GSE132465, GSE132257, https://cellxgene.cziscience.com/collections/1cbfb478-2c7f-4d15-b522-9f74e9fe52a8	涵盖中国、韩国的多中心样本；融合了 10x 和 SMART-seq2 数据。	提升鲁棒性： 加入 GSE150115 后，炎症背景（UC）的样本来加多样。这能确保识别出的 Pre-driver 亚群不是某个单一数据批次效应，而是具有 跨队列的一致性 。
阶段二：时空演化分析	GSE150115, GSE125527 , GSE132465, GSE144735	炎症阶段（UC）→原发癌阶段（CRC）。	精准溯源： 利用两份 UC 数据集构建拟时序的起点，可以更精确地定义免疫细胞在炎症微环境下发生“初次极化”的分子特征。
阶段三：MIL 预测建模	发现集：GSE178341 验证集：GSE132465	34对 MMRd/p 样本；23例独立原发癌。	算法深度： 利用明确的临床标签训练 MIL 模型，在单细胞层面定位区分 MMRp/d 的“关键实例（Instances）”。
阶段四：机制深挖	GSE178341, GSE144735	MMR 状态 + 肿瘤边界/核心空间信息。	通路解析： 结合通讯（CellChat）与代谢（scMetabolism），释 Pre-driver 亚群如何干扰 T 细胞功能。
阶段五：临床广度验证	GSE188711 , TCGA-COAD	左右侧 CRC 标注；大样本 Bulk 队列。	临床价值： 证明 Pre-driver 丰度是独立于解剖部位（左右侧）MMR 状态的普适性预后指标。

第一阶段：构建 CRC 免疫动态演化 Atlas（scVI 整合）

核心目标： 在消除批次效应的同时，保留从“炎症”到“中晚期癌症”的连续性状态转换。

- 数据整合 (GSE146771, GSE132465, GSE132257, GSE125527):**
 - 使用 scVI 建立生成式模型。利用其 `latent space` 进行 UMAP/t-SNE 可视化。
 - 深度分析： 计算 Mixing Metric (如 LISI score) 证明整合效果。对比 scVI 与传统 Harmony 的差异，强调 scVI 在保留微弱生物学信号（如罕见免疫亚群）上的优越性。
- 免疫细胞图谱精修：**
 - 细分 T 细胞（CD4+, CD8+, Treg, Th17）和髓系细胞（TAMs, cDCs, pDCs, Monocytes）。
 - 深度分析： 使用 Cluster Stability Analysis (如 Bootstrap) 证明聚类结果的稳健性。

第二阶段：识别 Pre-driver 亚群及其时空演化轨迹

核心目标： 定义“前驱动”抑制亚群，并证明其在肿瘤发生早期的关键作用。

- 拟时序分析 (GSE125527, GSE132465):**
 - 利用 Monocle3 或 Palantir 建立从炎症上皮到肿瘤微环境的免疫演变分支。
 - 深度分析： 识别在分支点（Branch point）起关键作用的基因。
- 空间定位模拟 (GSE144735 - Border vs Core):**
 - 分析 Pre-driver 亚群在 Border（边界） 的富集程度。
 - 深度分析： 计算 Infiltration Score。如果边界处的抑制细胞比例远高于核心区，说明其构建了阻碍 T 细胞进入的“物理屏障”。
- 转录调控网络 (SCENIC):**
 - 挖掘该亚群特异性的 Regulons（转录因子及其靶基因）。
 - 深度分析： 寻找在演化路径上表达量逐渐升高的 TF，作为潜在的治疗干预靶点。

第三阶段：基于多示例学习 (MIL) 的 MMRp/d 异质性建模

核心目标： 将生物学发现与临床最关键的分型（MMRp/d）联系起来，增加算法深度。

- MIL 预测模型构建 (GSE178341):**
 - Bag 构造： 34 名 MMRd 患者 vs MMRp 患者。
 - Attention 权重解析： 训练模型后，提取每个细胞的 Attention Score。
 - 深度分析： 统计不同亚群的平均权重。重点看一下阶段二识别出的 Pre-driver 亚群在 MMRp 患者中是否具有最高的注意力分值（可证明该亚群是导致 MMRp “冷肿瘤”特征的核心因素）。
- 单细胞层面的响应模拟：**
 - 比较 MMRd 样本中 T 细胞的激活特征与 MMRp 中 Pre-driver 亚群的压制特征。
 - 深度分析： 使用 Augur 或类似工具计算各细胞类型对 MMR 分型的“响应潜力值（Predictability）”。
- 权重迁移验证 (Weight Transfer)**
 - 操作： 将在 GSE178341 训练好的 Attention-MIL 模型参数锁定，直接输入 GSE132465 的细胞数据。
 - 目标： 查看模型是否能自动识别出类似的“高权重（High Attention）”细胞。如果 GSE132465 中某些患者表现出极高的 Pre-driver 亚群权重，你可以进一步挖掘这些患者的临床特征（如是否为右半结肠，预后是否较差）。
- 识别“冷热肿瘤”的分类器验证**
 - 操作： 利用 GSE178341 定义出 MMRp（冷）和 MMRd（热）的“免疫指纹（Signature）”。
 - 目标： 在 GSE132465 中，通过 MIL 模型对患者进行“冷热评分”。

- 深度分析： 结合 GSE132465 自带的配对正常组织数据。验证这种 Pre-driver 亚群是否是肿瘤特异性的，即：MIL 模型应该只在肿瘤样本中分配高权重，而在配对正常组织中不分配。
- MIL 的可解释性分析**
 - 注意力热图（Attention Heatmap）： 在 GSE132465 中，将 Attention Score 映射回 UMAP 图。你会发现某些细胞虽然在传统聚类中属于同一类，但在 MIL 模型眼中，只有靠近肿瘤边缘或处于特定分化阶段的细胞才有高分。
 - 亚群定义的普适性： 证明在两个数据集中，高权重的“Pre-driver”细胞具有高度重合的 Marker 基因。

第四阶段：细胞通讯耦合与生物学机制挖掘

核心目标： 解释“它是如何抑制免疫的”。

- 细胞通讯网络 (CellChat / NicheNet):**
 - 分析 Pre-driver 亚群与其他细胞（尤其是 CD8+ T 细胞和成纤维细胞）的通讯。
 - 深度分析： 寻找 Exhibitory Ligand-Receptor pairs。分析这些信号在 MMRp vs MMRd 中的强度差异。
- 代谢微环境模拟 (scMetabolism / Compass):**
 - 模拟该亚群的代谢通量（如乳酸代谢、脂肪酸氧化）。
 - 深度分析： 探讨是否通过代谢竞争（Metabolic competition）夺取了 T 细胞所需的营养，从而在 MMRp 环境中胜出。

第五阶段：外部临床队列验证（从单细胞到 Bulk）

核心目标： 提高结论的普适性，确保能被同行评审接受。

- 反褶积分析 (TCGA-COAD):**
 - 使用阶段一确定的 Marker 基因，在 TCGA 数百例样本中计算 Pre-driver 亚群的丰度。
 - 深度分析： 绘制 Kaplan-Meier 生存曲线。证明该亚群丰度高 = 预后差。
- Pre-driver 亚群丰度的“空间分布偏好”分析(GSE188711):**
 - 分析该亚群在左侧与右侧 CRC 中的分布差异，解释临床上右侧 CRC 对免疫治疗响应差异的底层机制。
 - 分析内容： 统计阶段二识别出的 Pre-driver 亚群在左侧（LCRC）与右侧（RCRC）中的占比差异。
 - 深度挖掘： （通常 RCRC 具有更高的免疫原性（与 MMRd 相关），但预后往往更差。）
 - 科学假设： 证明 RCRC 中虽然免疫细胞多，但 Pre-driver 抑制亚群的比例也同步升高，形成了“补偿性免疫抑制”。
 - 可视化： 使用 Boxplot/Split-UMAP 展示该亚群在左右侧的富集情况，并计算显著性
- “解剖部位”驱动转录组极化分析**
 - 分析内容： 提取左右侧样本中的 Pre-driver 亚群，进行差异基因（DEG）分析。
 - 深度挖掘： 利用 GSEA (Gene Set Enrichment Analysis)，探索右侧 Pre-driver 亚群是否具有更强的代谢活性或更强的排斥 T 细胞的能力。

预期结果（数据图供参考，以实际分析结果为准，数据图越丰富越好）

- Figure 1. 跨疾病阶段 CRC 免疫微环境全景图谱 (scVI 整合)

核心： 证明数据的深度整合与从炎症到癌的细胞组成演变。

- Panel A (UMAP): 全免疫细胞图谱，按数据集（GSE146771, GSE132465 等）着色，展示批次效应消除效果。
- Panel B (UMAP): 按疾病阶段（Normal, UC-Inflammation, Early-Cancer, Late-Cancer）着色，观察细胞漂移。
- Panel C (Composition): 各样本免疫亚群比例堆积柱状图，展示随疾病进展而扩张/缩减的群。
- Panel D (Heatmap/Dotplot): 各细分亚群（T, B, Myeloid, NK）的经典 Marker 基因表达。

- Panel E (LISI Score): 定量比较 scVI 与传统方法 (Harmony, Seurat) 在混合度和生物学特征保留上的评分。
- Panel F (Cluster Stability): 针对关键聚类的 Bootstrap 评分图, 证明 Pre-driver 亚群定义的统计稳健性。

• Figure 2. “前驱动”抑制亚群的演化轨迹与空间分布

核心: 定位 Pre-driver 亚群, 并证明其在“肿瘤边界”的空间阻断作用。

- Panel A (Trajectory): 拟时序演变图 (Monocle3), 展示 T 细胞/髓系细胞从 UC 演变为抑制态的轨迹。
 - Panel B (Dynamic Expression): 沿拟时序分布的关键驱动基因热图, 标记进入癌症状态的转折点。
 - Panel C (Spatial Map): 基于 GSE144735 的 Border vs Core 映射图, 展示抑制群的空间定位偏好。
 - Panel D (Barplot): 计算 Infiltration Score, 对比 Pre-driver 亚群在肿瘤边缘与内部的富集丰度。
 - Panel E (SCENIC): 识别驱动该亚群的 Regulon 网络 (如 HIF1A 或 STAT3), 展示其核心转录调控逻辑。
- #### • Figure 3. 基于多示例学习 (MIL) 识别决定 MMRp/d 异质性的关键实例

核心: 利用深度学习自动挖掘预测 MMR 分型的关键细胞特征。

- Panel A (Model Schema): Attention-MIL 模型框架示意图 (从 Patient Bag 到 Cell Instance)。
- Panel B (Performance): 在 GSE178341 中区分 MMRp 与 MMRd 的 ROC 曲线和 PR 曲线。
- Panel C (Attention UMAP): 将 Attention Score 投影回总图谱, 高分区域应锁定在 Pre-driver 亚群。
- Panel D (Subgroup Weight): 各细胞亚群在模型中的权重排名分布, 证明 Pre-driver 细胞对分类的贡献度。
- Panel E (Augur Analysis): 使用 Augur 计算各亚群对 MMR 状态的响应敏感度 (Predictability Score)。
- Panel F (Transfer Validation): 将训练好的模型迁移至 GSE132465, 验证其在外部队列预测“冷/热”肿瘤的稳定性的。

• Figure 4. Pre-driver 亚群诱导免疫逃逸的通讯与代谢机制

核心: 回答“该亚群如何抑制免疫”的生物学逻辑。

- Panel A (CellChat Circle): 展示 Pre-driver 亚群与其他细胞 (CD8+ T, CAF) 的通讯总强度。
- Panel B (Bubble Plot): 重点分析在 MMRp 中显著增强的受配体对 (如 LAG3-LGALS9, PVR-TIGIT)。
- Panel C (NicheNet): 预测 Pre-driver 亚群分泌因子诱导 CD8+ T 细胞进入 Exhaustion 状态的下游靶基因。
- Panel D (Metabolic Flux): 基于 scMetabolism 的通路评分对比, 展示该亚群的代谢偏好 (如腺苷代谢)。
- Panel E (Compass Map): 模拟关键代谢物的消耗与竞争图, 揭示代谢拮抗导致 T 细胞失活。
- Panel F (GSEA): Pre-driver 亚群在 MMRp 与 MMRd 患者中的通路差异富集, 如“免疫耐受”和“缺氧”。

• Figure 5. 临床解剖部位 (左右侧) 的异质性验证 (GSE188711)

核心: 解释右侧结肠癌预后较差且免疫反应复杂的底层机制。

- Panel A (Split-UMAP): 比较左侧 (LCRC) 与右侧 (RCRC) 的细胞分布, 突出 Pre-driver 亚群的富集差异。
- Panel B (Barplot): 左右侧样本中 Pre-driver 亚群占比的显著性检验 (Boxplot)。
- Panel C (Volcano Plot): LCRC 与 RCRC 中 Pre-driver 亚群的转录组差异基因。
- Panel D (Pathway Inversion): 展现 RCRC 中 Pre-driver 亚群表现出更强的“基质重塑”和“血管生成”特征。
- Panel E (Correlation): 计算 Pre-driver 丰度与患者年龄、分期等临床特征的相关性热图。
- Panel F (Signature Similarity): 证明左右侧提取的 Pre-driver 特征与 MMRp 提取的特征具有高度一致性。

• Figure 6. 外部大规模 Bulk 队列的临床预后与靶向潜力验证

核心: 实现从单细胞发现到临床应用价值的跨越。

- Panel A (Deconvolution): 利用 TCGA-COAD 队列反褶积得到的 Pre-driver 亚群丰度热图。
- Panel B (KM Curve): 总体生存率 (OS) 分析: 高丰度 Pre-driver 群组 vs 低丰度组。
- Panel C (Forest Plot): 多因素 Cox 回归, 证明 Pre-driver 评分是独立于分期和左右侧的预后因子。

补充材料建议:

- Supp Fig 1: 所有数据集的 QC 质控曲线 (nCount, nFeature, mt%)。

- Supp Fig 2: 特异性亚群（如不同的 TAM 亚型）的 Marker 基因扩充列表。
- Supp Fig 3: MIL 模型在不同超参数配置下的鲁棒性测试结果。
- Supp Fig 4: 针对 GSE132465 正常组织（Normal）中 Pre-driver 权重极低的对照分析。
- Supp Fig 5: 代谢与通讯的补充路径：例如针对内皮细胞、成纤维细胞的补充通讯网络；Panel B: Compass 算法预测的单细胞代谢通量明细表。